

CardioVision AI

Relatório de Pré-processamento e Classificação de Imagens Médicas (ECG)

Projeto: Classificação de Imagens Médicas com Deep Learning | Data: 15/06/2026

1. Introdução

Este trabalho implementa um pipeline completo para classificação automática de eletrocardiogramas (ECG) em quatro categorias clínicas: batimentos normais, batimentos anormais, infarto agudo do miocárdio e histórico pós-infarto. Aplicam-se técnicas de visão computacional — pré-processamento, CNN construída do zero e transfer learning com ResNet50 — com avaliação por acurácia, matriz de confusão, precisão, recall e F1-score.

2. Parte 1 — Pré-processamento e Organização

Dataset: ECG Heartbeat Categorization Images (Kaggle, domínio público), com 928 imagens em 4 classes. Escolheu-se por ser acessível, já rotulado por pasta e representativo de triagem cardíaca por imagem.

Etapa	Técnica	Justificativa
Leitura	OpenCV (imdecode + fromfile)	Incompatível com caminhos Unicode no Windows
Cor	BGR → RGB	Padrão esperado por frameworks de deep learning
Redimensionamento	224 × 224 px	Entrada compatível com ResNet50 / VGG16 (ImageNet)
Normalização	pixel / 255 → [0, 1]	Estabiliza gradientes e acelera convergência
Formato	JPEG (qualidade 95)	Uniformiza armazenamento e leitura nos notebooks
Split estratificado	70% / 15% / 15%	Mantém proporção das classes; teste reservado para métricas finais

Após o pipeline: treino 649 imagens, validação 139, teste 140. Metadados salvos em `data/processed/metadata.json`. Seed fixa (42) garante reprodutibilidade entre notebooks.

3. Parte 2 — Classificação com CNN

CNN do zero: quatro blocos Conv2D (32→256 filtros) + MaxPooling, camada densa (512), Dropout (0,5) e softmax (4 classes). Otimizador Adam (lr=1e-3), EarlyStopping e ModelCheckpoint.

Transfer Learning (ResNet50): base ImageNet congelada, pré-processamento específico do ResNet, camadas finais GlobalAveragePooling → Dense(256) → Dropout → Dense(4). Learning rate 1e-4 para fine-tuning parcial.

Avaliação: métricas calculadas no conjunto de teste — acurácia, matriz de confusão, precisão, recall e F1-score (scikit-learn). Validação e teste usam shuffle=False para alinhar labels e previsões.

Protótipo: simulador interativo no notebook `04_prototype_interface.ipynb` (ipywidgets), permitindo selecionar ECG de teste e modelo (CNN ou ResNet50) com barras de probabilidade.

4. Conclusão

O pipeline garante rastreabilidade do dado bruto à inferência. A comparação entre CNN simples e ResNet50 evidencia o ganho típico do transfer learning em datasets médicos de porte moderado. Os notebooks executam localmente ou no Google Colab.

Nota: sistema exclusivamente educacional — não substitui diagnóstico clínico.